Introdução à Aprendizagem Automática 2026/2027

Aprendizagem Não Supervisionada - Mini Projeto de Laboratório I

6 de outubro de 2026

1 Introdução

Este mini-projeto tem como objetivo a familiarização prática com os algoritmos de aprendizagem não supervisionada lecionados nas aulas teóricas. Em particular, é esperado que os alunos apliquem os conhecimentos adquiridos e os expandam seguindo um conceito de aprendizagem ativa, tendo por base um conjunto de dados reais. Este mini-projeto terá componentes de programação (implementação de algoritmos), aplicação dos algoritmos para visualização e interpretação/análise dos resultados. As aulas de laboratório servirão para acompanhar e avaliar de forma contínua a progressão dos projetos, mas é esperado que os alunos dediquem tempo ao trabalho fora das aulas de laboratório.

O trabalho deverá ser realizado em **grupos de 2 alunos**, sendo que cada grupo deve trabalhar sozinho. A linguagem de programação a usar será o **Python**. Recomenda-se a instalação de, pelo menos, as seguintes bibliotecas: *numpy, scipy, matplotlib, pandas, scikit-learn*. Alternativamente, os alunos poderão usar o **Google Colab**[*]como plataforma para implementarem todo o código do projeto. O Colab tem o benefício de que pode ser associado a uma conta de endereço Gmail, interliga com o Google Drive e não necessita de instalação das bibliotecas mais populares.

2 Submissão e Regras Sobre o Uso de IA

Cada grupo deve submeter um **ficheiro zip** no Fénix até dia **17 de Outubro de 2026**, com os seguintes ficheiros:

- Um **ficheiro Python**, idealmente um *Jupyter Notebook*, contendo todo o código desenvolvido para o projeto. Código que faça parte da avaliação, nomeadamente que corresponda a perguntas para escrita de funções, deve estar claramente indicado com comentários.
- O **PDF do enunciado preenchido** com as respostas às questões nos campos indicados - isto pode ser feito preenchendo diretamente o PDF num browser ou num leitor de PDF. Posteriormente, o PDF deve ser *flattened*/trancado, o que pode ser feito escolhendo a opção de imprimir o PDF e posteriormente guardar novamente apenas as páginas pretendidas.
- Todos os **gráficos/figuras pedidas**, identificadas com o nome da questão (*e.g.*, "PartI2a.jpg"). Os eixos e pontos devem ser sempre corretamente identificados.
- Os documentos do **compromisso de honra** e da declaração do uso de IA preenchidos e assinados. Ver templates dos mesmos nos anexos A e B.

Uso de IA: Os laboratórios de Introdução à Aprendizagem Automática têm uma política de "semáforo amarelo"quanto ao uso de IA. Permite-se o uso da mesma para auxílio na geração de código e na compreensão de bibliotecas e funções das mesmas. Adicionalmente, é permitido o uso de IA como suporte à aprendizagem ativa. **Todavia, os alunos deverão ser capazes de responder a questões feitas sobre o código durante as aulas, sendo isto contabilizado na componente da avaliação contínua. Não é permitido o uso de IA para gerar respostas.**

[*]https://colab.research.google.com/

3 Avaliação

A nota do mini-projeto I terá em conta o **código entregue**, as **respostas às questões** e a **avaliação contínua** a decorrer durante as duas sessões de laboratório dedicadas a este projeto. A avaliação contínua consistirá na interação com o docente de laboratório, sendo que a mesma poderá ter diferentes formatos. Este projeto terá um peso de 35% na nota final do **laboratório** da cadeira.

4 Dados

4.1 Descrição dos dados

O projeto tem como objetivo principal a análise não supervisionada de vídeos de fisioterapia de vários pacientes que sofreram acidentes vasculares cerebrais (AVC). Os pacientes foram gravados a fazer várias repetições de diferentes atividades diárias, cujo objetivo é promover a reabilitação motora. Os vídeos foram adquiridos usando uma câmera ZED da StereoLabs. Posteriormente recorreu-se ao MediaPipe[†], um modelo baseado em redes neuronais, para a deteção e extração de um conjunto de marcadores a cada 2 segundos de vídeo. Estes marcadores, como exemplificados na Figura 1, correspondem a posições 2D $(u_{j,t}^{(i)}, v_{j,t}^{(i)})$ de várias partes do corpo humano j e podem ser ligados por arestas, permitindo a formação de um esqueleto representativo da pose do paciente no dado instante t.

Formalmente, o conjunto de dados a ser usado consiste em sequências de poses de um número desconhecido de pacientes. Também não são conhecidos os tipos de exercícios que foram executados. Cada sequência $i \in \{0, .., 70\}$ contém um número variável de poses. Cada pose adquirida no instante t é representada por um conjunto de $j \in \{0, ..., 32\}$ marcadores, cada um deles definido por uma posição $(u_{j,t}^{(i)}, v_{j,t}^{(i)})$. Ou seja, dada uma sequência i, cada pose num instante t corresponde ao seguinte vetor: $[u_{0,t}^{(i)}, v_{0,t}^{(i)}, u_{1,t}^{(i)}, v_{1,t}^{(i)}, ..., u_{32,t}^{(i)}, v_{32,t}^{(i)}]$

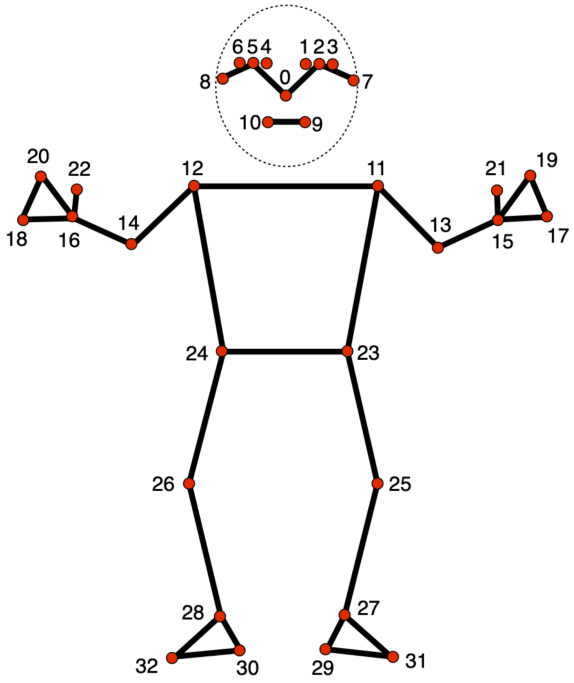


Figura 1: Esqueleto obtido com o MediaPipe Skeleton Keypoints. Cada número corresponde a um marcador e estes seguem a mesma ordem que no projeto.

[†]https://github.com/google-ai-edge/mediapipe

4.2 Upload e navegação preliminar dos dados

Os dados encontram-se guardados no formato pickle (.pkl), podendo ser integrados no código através da biblioteca *pandas*, que criará uma matriz estruturada de dados. O código abaixo providencia alguns exemplos sobre como navegar um:

Listing 1: Código de apoio à leitura e navegação de *dataframes*.

```
import numpy as np
import pandas as pd
from sklearn.preprocessing import StandardScaler

#Importar os dados e verificar dimensões
df_train = pd.read_pickle('Xtrain.pkl')
print(df_train.shape)

#Concatenar todas as poses e sequências numa matriz de dados.
#Esta matriz vai ser usada na maior parte do projeto
X = np.concatenate(df_train['Skeleton_Sequence'].to_numpy())
print(X.shape) # N X 66

#Normalização dos dados - centrar + escalamento (recomendando e crítico para o PCA)
scaler = StandardScaler()
X_norm = scaler.fit_transform(X)

#Aceder a uma sequência específica do dataframe, por exemplo a primeira
seq = df_train.iloc[0]['Skeleton_Sequence']
print(seq.shape) # T X 66
```

Enunciado

Grupo: 109 **Turno:** IAAutomL06

Nome: David Alves **IST ID:** 107603

Nome: Luana Oliveira **IST ID:** 109251

Parte I - *k-means*

Esta secção tem como objetivo explorar o algoritmo *k-means*, a sua inicialização e optimização, assim como a aplicação do mesmo aos dados de fisioterapia.

1. **Implementação:** Modifique o código abaixo de forma a implementar o algoritmo *k-means*. O código deve permitir: i) a estimação da posição de K centróides definidos pelo utilizador; ii) a inicialização da posição dos mesmos usando o método aleatório ou o *k-means++*; iii) o cálculo da função de custo; e iv) a associação de novos pontos aos centróides estimados. As funções implementadas devem estar claramente identificadas no código entregue.

Listing 2: Código a modificar para a implementação do *k-means*.

```
import numpy as np

# NÃO MODIFICAR A SEED
np.random.seed(555)

def kminit(X, K, flag):
    #Inicialização - pode ser aleatória ou recorrendo ao k-means++

    '''
    Input:
    X: um numpy ndarray com dimensões (N,d), em que cada linha corresponde
    a uma amostra
    K: um inteiro que corresponde ao número de clusters a estimar
    flag: indicador sobre o tipo de inicialização. Sugestão: "random" e "km++"
    para cada versão

    Output:
    C: um numpy ndarray com dimensões (K,d), onde cada linha é a inicialização
    de um dos centróides
    '''

    # A inicialização do primeiro centróide é fixa
    N = X.shape[0]

    C = []
    C.append(X[np.random.randint(N)])

    # TODO: complete o código para inicializar os K-1 centróides de acordo com a flag

    return C


def kmeans_custo(X, C, s):
    #Calcula a função de custo do k-means

    '''
    Input:
    X: um numpy ndarray com dimensões (N,d), em que cada linha corresponde
    a uma amostra
```

```
    C: um numpy ndarray com dimensões  (K,d), onde cada linha é a incialização
    de um dos centróides
    s: um numpy ndarray de dimensão (N,) onde cada entrada é um inteiro que representa o
    indíce do cluster para o ponto x^i

    Returns squared Euclidean distances from each point to the center of its assigned cluster
    '''

    # TODO: calcule a função de custo

    return

def kmeans(X, K, flag):
    #Aplica o algoritm k-means à matriz de dados X.

    '''
    X: um numpy ndarray com dimensões (N,d), em que cada linha corresponde
    a uma amostra

    K: um inteiro que corresponde ao número de clusters a estimar

    flag: indicador sobre o tipo de inicialização. Sugestão: "random" e "km++"
    para cada versão

    Devolve um tuplo contendo (C, z):
        C: um numpy ndarray com dimensões  (K,d), onde cada linha é a incialização
        de um dos centróides
        z: um numpy ndarray de dimensão (N,) onde cada entrada é um inteiro
        que representa o indíce do cluster para
        o ponto x^(i)
    '''

    #TODO: Implemente o algoritmo do k-means, com um critério de paragem apropriado.
    #Use as funções definidas acima

    return
```

2. **Selecionar o número de centróides e inicialização**

R2.a) Corra a implementação para os dados de fisioterapia, usando a inicialização aleatória e com um número variável de centróides K. Note que deverá usar uma matriz X que contenha todas as poses, independentemente da sequência. Crie um gráfico do valor função de custo em função do número de centróides, escolha o número óptimo e justifique a escolha.

Utilizámos a inicialização aleatória (de K=1 a 14) sobre a matriz X_norm, que contém todas as N = 8374 poses normalizadas com d = 66 dimensões.Para K = 1, obtivemos J = 552,684 = N x d, o que era esperado uma vez que cada coluna tem variância 1 após a normalização, confirmando a implementação do algoritmo. Através do método do cotovelo, identificámos K = 7 como o número óptimo de centróides. O custo desce de K = 5 para K = 6 (18,8%) e de K = 6 para K = 7 (15,1%), mas de K = 7 para K = 8 a redução é de apenas 7,0%, assinalando o ponto a partir do qual adicionar centróides deixa de compensar.Por ser realizada apenas 1 execução por K, a inicialização aleatória prendeu o K-means em mínimos locais, originando subidas de custo em K = 9 e K = 13, impossíveis no ótimo global tratando-se de recuperações desses maus mínimos locais, e não de ganhos reais.

R2.b) Repita a questão anterior, mas agora utilizando a inicialização do *k-means++*.

Repetimos a R2a com a inicialização K-means++ e observámos duas características no gráfico: a curva é mais suave, sem os picos em K = 9 e K = 13 da curva aleatória, e o custo é menor do que a inicialização aleatória para valores pequenos de K. Isto decorre do facto de o K-means++ espalhar os centróides iniciais, reduzindo a probabilidade de o algoritmo ficar preso em maus mínimos locais.O ponto K = 7 foi escolhido como o número óptimo de centróides, apresentando uma descida de K=6→7: 15,9%, K=7→8: 9,3%. Verifica-se uma descida reduzida de K =9→10 (2,3%) e K =10→11 (18,3%), trata-se do mesmo padrão de recuperação após um mau mínimo local. O objetivo é o melhor equilíbrio entre custo e complexidade, tendo K = 7 menos 4 centróides do que K = 11. Esta análise assenta só 1 execução, pelo que a pergunta R2c determinará o K óptimo.

R2.c) Corra 20 vezes cada uma das alíneas anteriores e represente num mesmo gráfico o valor médio da função de custo e o desvio padrão para cada número de centróides K e tipo de inicialização. Qual das inicializações aparenta ser melhor? Porquê?

Para os K pequenos (K=2 a 5), as diferenças nas médias são residuais (até 3,0%). No K = 3, o K-means++ apresenta uma média 3,0% pior e o maior desvio padrão (42 043 vs 27 755 da aleatória). Se o K-means++ escolher uma pose outlier, "desperdiça" um dos poucos centróides. Por outro lado, para K grandes (K=6 a 14) o k-means++ apresenta médias inferiores (entre 1,9% e 8,0%, à exceção de K=8 com +0,4%) e desvios padrão menores (em K=6, o dp cai de 21 392 para 8 110). Ao espalhar os centróides iniciais, o k-means++ a probabilidade de mínimos locais maus e favorece soluções mais consistentes. O K óptimo passa a ser 11 (10→11: 10,2%; depois 4,6%, 6,2% e 6,1%) e a melhor inicialização é o k-means++ para K grande. A divergência face às alineas anteriores explica-se por por estas resultarem de uma só execução, com ruído, e a média de 20 é mais fiável.

3. **Visualização:** Escreva código que permita visualizar a pose associada a cada centróide. Use como referência a Figura 1. Não se esqueça de inverter a normalização para recuperar os dados no sistema de coordenadas original.

   R3.a) Com base nas análises feitas nas alíneas anteriores, escolha o melhor modelo e visualize os centróides. Guarde a figura e comente o que observa.

Utilizámos o modelo K-means++ com K = 11, após as conclusões da R2c, e as poses foram obtidas com a normalização invertida das coordenadas.O centróide 8 é o maior (2350 de 8374 poses, cerca de 28%), por, provavelmente, corresponder a uma postura neutra de descanso, assumida no início, entre repetições ou no fim do exercício. Várias poses refletem atividades diárias: levantar o joelho (5, 10); simula a subir um degrau, um de cada lado; levar as mãos ao rosto (2); abaixar-se (0, 4, 6, 9). Por fim, nas poses de pé, variam os braços: braços ao longo do corpo (1), 2 mãos na cintura (3) e (7) o paciente tem a mão esquerda na cintura com o braço direito afastado. Os ombros desnivelados (ex.: 8 com os pés no chão) pode decorrer de limitações motoras associadas ao AVC. No entanto, em coordenadas 2D, uma ligeira rotação do corpo pode gerar um desnivelamento nos ombros.

4. **Visualização em 2D:** Esta questão deve ser abordada após fazer as alíneas referentes ao PCA. Faça uma projeção 2D dos centróides do modelo escolhido na alínea anterior e dos dados.

   R4.a) Faça um gráfico da projeção obtida, distinguindo os centróides dos restantes pontos. Pinte os pontos de acordo com o centróide a que foram associados. O que pode dizer sobre os clusters? Como se relacionam com as visualizações feitas na questão anterior?

Os clusters 0, 4 e 6 estão afastados do centro, enquanto o cluster 2 surge também afastado (mãos no rosto). Já os clusters 3 e 5 surgem muito amontoados, tal como os clusters 8 e 10, estando o cluster 7 também próximo destes últimos.
A PC1 é dominada por v da cabeça e dos ombros (39% da variância); já a PC2 pelas u dos mesmos marcadores (24%). Assim, o cluster 4 isola-se na PC1 (maior dobragem do tronco), enquanto os clusters 0 e 6 se isolam na PC2 (deslocamento lateral). Já os clusters 5 e 10 (caracterizados na R3a pela elevação do joelho) aparecem colados a poses eretas normais em 2D (o 5 junto ao 3 e o 10 junto ao 8): a informação das pernas e pés só passa a ter peso relevante a partir da PC3 (12% da variância), ficando excluída deste plano bidimensional. Há duas caudas alongadas de pontos a partir do 8: uma em direção aos clusters 0 e 6 (passando pelo 9) e outra até ao cluster 4 (passando pelo 1). Estas trajetórias contínuas refletem a própria sequência dos frames de vídeo (poses intermédias).

Parte II - PCA e Redução de Dimensionalidade

Esta secção tem como propósito a exploração do PCA como técnica de redução de dimensionalidade e exploração preliminar de um conjunto de dados. Pretende-se também demonstrar como o PCA pode ser utilizado para visualizações de dados de "elevada"dimensão em 2D ou 3D.

5. **Decomposição:** Usando a função `PCA` da biblioteca `scikit-learn`, faça a decomposição da matriz de poses X. Não defina o número de componentes nem o threshold de variância explicada.

   R5.a) Quantas componentes são precisas para obter 95% da variância explicada? Explique os passos que executou para determinar este valor. Se necessário, pode incluir figuras de suporte.

As poses foram organizadas numa matriz X com 66 características, normalizadas com StandardScaler antes da aplicação do PCA. O número de componentes foi determinado pela variância explicada acumulada, selecionando o mínimo necessário para atingir 95%. Obtiveram-se 8 componentes principais, que explicam 95,2464% da variância total.

   R5.b) Escreva código que permita inspecionar a contribuição de cada característica no espaço original, *i.e.*, os marcadores e as suas componentes (u, v), relativamente a cada componente estimada pelo PCA. Depois, inspecione as componentes identificadas na alínea anterior, reporte o top-10 das *features*/características que mais contribuem e os seus pesos e comente aquilo que observa. Consegue observar alguma relação com os centróides obtidos pelo *k-means* na questão **R3.a)**?

Para analisar a contribuição das características originais em cada componente principal, inspecionaram-se os loadings das oito componentes identificadas na R5.a, selecionando as características com maior valor absoluto de peso.

As duas primeiras componentes explicam 62,84% da variância total. A PC1 (39,03%) é dominada pelas coordenadas verticais "v" dos marcadores da metade superior do corpo, com pesos predominantemente positivos, captando sobretudo variações na posição vertical. A PC2 (23,81%) apresenta contribuições relevantes das coordenadas horizontais "u" e verticais "v", com sinais opostos, refletindo variações na configuração espacial do corpo. A PC3 destaca as coordenadas "u" dos marcadores 28, 32, 30 e 26, enquanto a PC4 evidencia as coordenadas "v" dos marcadores 31, 29 e 27. As restantes componentes captam padrões adicionais de variabilidade.

A relação com os 11 centróides obtidos pelo K-means na R3.a permite observar diferenças nas configurações médias dos esqueletos. Por exemplo, os centróides 0 e 6 apresentam posturas mais flexionadas, enquanto os centróides 1, 7 e 8 correspondem a configurações mais eretas. Também se observam diferenças na posição dos braços, distinguindo configurações com os braços junto ao tronco de outras com maior extensão lateral. Estas diferenças são compatíveis com a variabilidade geométrica identificada pela PCA.

Em suma, a PCA permite identificar as características que mais contribuem para a variabilidade das poses, enquanto os centróides facilitam a interpretação visual das diferenças entre os grupos. Esta relação deve, contudo, ser entendida qualitativamente, uma vez que a associação quantitativa entre cada centróide e as componentes principais exige a sua projeção no espaço da PCA. Além disso, as diferenças observadas podem refletir tanto alterações de postura como efeitos da perspetiva da câmara.

6. **Redução de dimensionalidade:** Escreva código para projetar a matriz de dados de fisioterapia numa dimensão mais baixa r, usando r componentes principais. Implemente também uma função que permita reconstruir a matriz de dados a partir da baixa dimensão. Escreva o seu próprio código usando a biblioteca `numpy` e não use funções já feitas do `scikit-learn`.

   R6.a) Faça uma redução de dimensionalidade para $r = 2$. Visualize os dados nesta nova dimensão e descreva o que observa.

Foi aplicado o PCA, para reduzir as 66 características originais a duas componentes principais, obtendo uma projeção de 8374 poses que explica 62,84% da variância total, o que dá evidência que a implementação está correta. Observa-se uma região central densa, da qual partem vários braços em diferentes direções, alguns terminando em concentrações de pontos, nomeadamente à esquerda, à direita e na região inferior. Estas concentrações poderão corresponder a poses frequentes, enquanto as zonas mais dispersas poderão refletir transições entre poses consecutivas. De acordo com a R5.b, a PC1 é influenciada sobretudo pelas coordenadas "v", enquanto a PC2 das coordenadas "u". Apesar das várias regiões de concentração, a sobreposição dos pontos não permite determinar claramente o número de clusters, sendo necessário complementar esta análise com outras visualizações.

   R6.b) Qual a variância explicada pelas duas componentes e o erro quadrático médio de reconstrução das poses em X? Em que marcadores/posições é que o erro é maior? Porquê?

As duas componentes principais explicam 62,84% da variância total. O erro quadrático médio de reconstrução (MSE), calculado sobre todas as poses e as 66 características, é 0,002589 no espaço original e 0,371601 no espaço normalizado. Os maiores erros absolutos ocorrem nos marcadores 15–22, correspondentes aos pulsos e às mãos, destacando-se o marcador 19 (MSE de 0,018261). Em contraste, os marcadores 23 e 24, correspondentes às ancas, apresentam erros reduzidos. Na R5.b, as coordenadas dos marcadores dos membros superiores também surgem entre as características relevantes das componentes PC3, PC5, PC6 e PC8, sugerindo que parte da sua variabilidade não é captada pelas duas primeiras componentes. A comparação do erro relativo e do desvio padrão permitirá determinar se os maiores erros absolutos resultam sobretudo da amplitude de movimento ou de uma representação menos eficaz pelo PCA.

R6.c) Repita a projeção e a alínea anterior, mas agora escolhendo r de modo a que o número de componentes explique 95% da variância. Compare os resultados com os obtidos para $r = 2$.

R6.c) Com oito componentes principais, a projeção passa a ter dimensão (8374 x 8) e explica 95,25% da variância, face aos 62,84% obtidos com duas componentes. Embora preserve mais informação, deixa de ser diretamente visualizável num gráfico 2D.
O MSE diminui de 0,002589 para 0,000287 no espaço original e de 0,371601 para 0,047536 no espaço normalizado, correspondendo a reduções de aproximadamente 9 e 7,8 vezes. Esta diferença deve-se às distintas escalas dos dados em cada espaço.
O erro do marcador 19 diminui de 0,018261 para 0,001493 (cerca de 91,8%), e o marcador 20 passa a apresentar o maior erro. Apesar da melhoria, permanecem 4,75% da variância por explicar, que pertence principalmente aos marcadores 15 a 22 devido a serem os de maior erro.
Para concluir se os pulsos e as mãos (marcadores 15–22) melhoram mais do que os pés, é necessário comparar a redução dos erros entre essas regiões.

Parte III - Misturas de Gaussianas (GMMs)

Esta secção tem como objectivo a exploração de um algoritmo de clustering com uma base probabilística, combinando o mesmo com técnicas de redução de dimensionalidade. Esta parte deve ser abordada após terem sido resolvidas as questões relativas ao PCA.

7. **Estimar um GMM em dimensão reduzida:** Utilizando a projeção obtida na alínea **R6.c)** estime um GMM usando a função `GaussianMixture` do `scikit-learn`. Permita que se estimem as matrizes de covariância completas e defina um número de componentes para a mistura que considere apropriado.

   R7.a) Reporte o número de componentes escolhido e justifique.

Analisámos o BIC e o AIC (K=1-30, r=8; 95,25% da variância). O BIC e o AIC não atinge um mínimo claro porque as poses são frames consecutivos de vídeo, não independentes. Usamos o cotovelo na descida percentual do BIC: Até K=5 há descidas acentuadas do BIC (17,7%, 12,5%, 6,6% e 2 para 3 é um mau ótimo local). De 5 a 9 mantém-se nos 2,3% - 3,2%. Por fim, K > 9, <2,0% e com ruído. Escolhemos K=9, a partir do qual as reduções do BIC são pequenas e instáveis. Face a K=5, representa melhor as posturas de R3a e fica mais próximo do K=11 do k-means

R7.b) Utilize o PCA obtido na Parte II para visualizar em 2D os clusters obtidos com o GMM, à semelhança do que fez para o *k-means* na questão **R4.a)**. Expanda o código de visualização para permitir inspecionar também as covariâncias estimadas. Comente o que observa.

Ao contrário do k-means (clusters esféricos), o GMM tem elipses alongadas ao longo das transições (como as componentes 3 e 8 ao longo da trajetória de flexão do tronco). As componentes do centro (4, 5, 6) têm elipses pequenas, e as da periferia (0, 7) são muito largas. O k-means não consegue isto, porque trata todos os clusters como tendo a mesma dispersão.
Na tabela cruzada, há boa correspondencia 2→1, 7→7, 4→3. O 5 e o 10 (joelho) separam-se, o que confirma a R4a: com r=8, a PC3 (pernas) entra no modelo (K-means 5 para GMM 6 e K-means 10 para GMM 5).
O GMM juntou o 0 e o 6 (baixar-se),e dividiu o 8 (repouse, 1599 na componente 4, pesos mais equilibrados, máx. 19%). A confiança média ≥ 0,961 sugere que a sobreposição das elipses é efeito da projeção 2D.

R7.c) Escreva uma função que permita visualizar no espaço original dos esqueletos as poses e respetivas covariâncias (por marcador), tendo por base o GMM estimado na dimensão reduzida. Faça uma figura das poses obtidas e compare os rsultados com os obtidos pelo *k-means*. Comente também aquilo que observa em termos de variância por marcador e pose.

Os marcadores 23 e 24 (ancas) têm variância quase nula em todas as componentes, o que sugere que as poses foram previamente centradas na anca. A componente 4 (repouso) tem a menor variância (pose estável), enquanto as componentes 0, 7 e 8 (transições) apresentam elevada variância na cabeça e no tronco superior (marcadores 0 a 10). Na componente 1 (mãos ao rosto), a maior variância está nos pulsos e mãos (marcadores 15 a 22), com elipses alongadas na vertical (subir e descer das mãos).As componentes de joelho elevado: a GMM 5 apresenta elevada variância no lado esquerdo (marcadores ímpares 25, 27, 29 e 31, elipses ao longo da canela: o joelho sobe e desce) e a GMM 6 no direito (marcadores pares 26, 28, 30 e 32). A a perna da GMM 5 varia mais (0,12 vs 0,08-0,10), o que sugere uma possível assimetria motora pós AVC. Na comparação com o K-means, os esqueletos quase coincidem (como a GMM 4 com o K-means 8, a GMM 5 com o 10 e a GMM 6 com o 5), e divergem nas 0, 7 e 8 (clusters fundidos/divididos). Além da pose média, o GMM dá a magnitude e a orientação espacial da variabilidade de cada articulação. Limitação: as elipses não incluem os 5% de variância descartados pelo PCA

8. **Escolher o número de componentes da mistura:** Um dos desafios das GMMs é a escolha do número de componentes. Nesta questão iremos explorar um algoritmo proposto por Figueiredo e Jain[‡] para estimar automaticamente o número de componentes.

   R8.a) Familiarize-se com o artigo de Figueiredo e Jain e explique, sucintamente, como é que os autores propõe estimar automaticamente e de forma não supervisionada o número de componentes de uma mistura. Discuta tambem como é que o método proposto se diferencia do algoritmo EM estudado nas aulas para as misturas de Gaussianas.

[‡]Figueiredo, Mario A. T., and Anil K. Jain. "Unsupervised learning of finite mixture models."IEEE Transactions on pattern analysis and machine intelligence 24, no. 3 (2002): 381-396.

A ideia central do método de Figueiredo e Jain é estimar automaticamente o número de componentes através do critério Minimum Message Length (MML). O algoritmo começa com um número elevado de componentes e modifica a atualização dos pesos no M-step: o peso de cada componente depende do seu suporte, dado pela soma das responsabilidades, subtraindo-se (N/2), onde (N) é o número de parâmetros da componente. Se o resultado for negativo, o peso é fixado em zero e a componente é eliminada.

Para reduzir a sensibilidade à inicialização, os autores utilizam o CEM², que atualiza as componentes sequencialmente e redistribui pelas restantes a massa da componente eliminada. Após a convergência, como esta não garante necessariamente um mínimo global do custo MML, o algoritmo elimina sucessivamente a componente com menor peso, repete a otimização e seleciona a solução com menor custo. Ao contrário do EM convencional, que exige um número fixo de componentes e pode requerer várias execuções com diferentes valores de (K), seguidas da comparação por critérios como BIC ou MDL, este método integra a estimação dos parâmetros e a seleção do número de componentes num único procedimento.

Parte IV - Questões Abertas

Este bloco tem como objetivo promover a iniciativa e creatividade de cada grupo. O objetivo será tirar partido das várias ferramentas de aprendizagem não supervisionada estudadas nas aulas e abordadas nos laboratórios e tentar responder a duas questões sobre os dados recebidos.

9. **Número e tipo de exercícios:** Consegue estimar quantos exercícios diferentes estão representados nas sequências fornecidas sem visualizar as mesmas? E em que consistem os mesmos? Indique um número, tente descrever os exercícios, e explique claramente o procedimento adoptado. Todo o código e figuras utilizadas devem ser submetidos. **Use as ferramentas de aprendizagem não supervisionada - Não deve visualizar as sequências para responder!**

Para identificar o número de exercícios distintos nas 71 sequências e a sua respetiva caracterização, sem recorrer à visualização direta dos vídeos, aplicou-se uma metodologia de agrupamento ao nível das sequências completas, resumindo cada uma num vetor de características para posterior clustering hierárquico pelo método de Ward. Construíram-se dois descritores independentes baseados exclusivamente nas métricas do modelo: 1. Assinatura de Movimento, calculada pelo desvio padrão temporal normalizado de cada uma das 66 coordenadas para isolar a mobilidade das regiões anatómicas independentemente da amplitude articular do paciente, e 2. o Saco de Poses, que mede a frequência relativa de frames alocados às 9 componentes do GMM da pergunta R7 para mapear o itinerário postural. A análise do coeficiente de silhueta para K: 2 a 10 (Fig PartIV9a) revelou uma concordância notável entre ambos os descritores, atingindo o valor máximo em K = 3, com 0,77 no movimento e 0,66 nas poses, acompanhada por dendrogramas com três ramos bem separados que se fundem a distâncias elevadas (4-5) em relação às fusões internas (<1,5). Esta partição em 3 exercícios é reforçada pela validação cruzada entre os dois métodos, que concordam em 69 das 71 sequências, distribuindo-se em 19 no Exercício 0; 27 no Exercício 1 e 23 no Exercício 2.

A interpretação biomecânica e a distribuição das poses por exercício, ilustradas no mapa de calor da Fig. PartIV9b, revelam a essência funcional de cada grupo. O Exercício 0, com 19 sequências e duração média de 59 frames, mobiliza pés, tornozelos e joelhos, apresentando como poses dominantes as elevações de joelho GMM 5 (53%) e GMM 6 (47%). A análise individual confirma que todas as 19 sequências contêm ambas as componentes em proporções próximas de 50/50, indicando que os pacientes alternam as pernas no mesmo exercício, com alternância das pernas. O Exercício 1, com 27 sequências e duração média de 204 frames, foca-se na flexão e inclinação do tronco, destacando-se a variabilidade na cabeça ao dobrar a coluna e o percurso pelas componentes GMM 4 (repouso, 22%), GMM 7 (transição, 20%) e GMM 0 (flexão/abaixar-se, 19%). Este exercício é cerca de três vezes mais longo do que os restantes, o que pode refletir maior lentidão/pausas e complexidade do controlo postural do tronco pós-AVC. Por fim, o Exercício 2, com 25 sequências e duração média de 70 frames, foca-se na motricidade dos membros superiores, sobretuno no indicador, polegar e pulso, sendo fortemente dominado pela pose de levar as mãos ao rosto, representada pela GMM 1 com 71%.

A hipótese de dividir o conjunto em 4 grupos foi rejeitada porque isolaria as sequências do Exercício 2 executadas com a mão contralateral, agrupando 23 na mão esquerda contra 2 na direita, tratando-se da mesma tarefa efetuada com o membro oposto, o que reduziria a silhueta e a concordância entre descritores. O facto de a grande maioria das sequências do Exercício 2 usar a mão esquerda sugere que este era o lado afetado em reabilitação na maioria dos pacientes. Por fim, a ligeira assimetria na dimensão dos grupos, divididos em 19, 27 e 25 sequências, pode indicar para a existência de repetições ou sequências em falta na recolha dos dados. Em suma, sem inspeção visual do vídeo, os dois descritores numéricos e a evidência gráfica das Fig. PartIV9a e PartIV9b apontam para a existência de 3 exercícios funcionais distintos: elevação alternada de pernas, flexão de tronco e alcance das mãos ao rosto.

10. **Número de Pacientes:** Consegue estimar quantos pacientes fazem parte deste conjunto de dados? Pode assumir que todos os pacientes fazem todos os exercícios. Todavia, poderão apresentar diferentes níveis de constrangimento motor, o que afetará a forma como se movem. Adicionalmente, os pacientes podem ter corpos distintos. Indique um número e explique sucinta mas claramente o procedimento adoptado para chegar ao mesmo. Todo o código e figuras utilizadas devem ser submetidos.

Para estimar o número de pacientes distintos sem recorrer à visualização direta das sequências, extraíram-se características geométricas das 71 sequências disponíveis, procurando representar a morfologia de cada indivíduo e reduzir a influência dos movimentos realizados durante os exercícios.

Inicialmente, calcularam-se as distâncias euclidianas entre dez pares de marcadores anatómicos, correspondentes aos ombros, ancas, braços, antebraços, coxas e pernas. Para reduzir a influência da escala corporal e da distância à câmara, normalizaram-se estas distâncias pelo comprimento do tronco (distância entre os pontos médios dos ombros e das ancas). Foram avaliados diferentes descritores temporais: a mediana, o percentil 90 e um descritor robusto, obtido através da divisão do percentil 90 dos comprimentos dos segmentos pelo percentil 90 do comprimento do tronco.

De seguida, aplicou-se o algoritmo k-means e o clustering hierárquico. A escolha do número de grupos foi fundamentada pelo silhouette score, pela estabilidade entre descritores e por testes de validação. Para o descritor robusto, o silhouette score atingiu 0.607 para K=2, indicando uma separação global muito forte. Contudo, ao analisar o agrupamento hierárquico para K=3, identificaram-se três grupos com dimensões muito equilibradas (24, 20 e 27 sequências, respetivamente).

A estabilidade dos resultados foi avaliada via teste split-half, dividindo cada sequência em duas metades. A comparação dos agrupamentos entre a 1.ª e a 2.ª metade revelou valores elevados de Adjusted Rand Index (ARI): 0.780 para K=2 e 0.749 para K=3, o que confirma que o descritor capta estrutura morfológica consistente e intrínseca às sequências. Para K=4, o algoritmo isolou uma única sequência (sequência 11), tratando-se claramente de um outlier pontual e não de um novo paciente.

Identificaram-se ainda alguns fatores de confusão: observaram-se correlações de Spearman com a duração da sequência em certos segmentos dos braços, o que sugere que sequências mais longas capturam extensões de braço mais completas. Além disso, a utilização de janelas fixas de 30 poses alterou os agrupamentos, demonstrando alguma sensibilidade à representação temporal.

Em suma, estimamos a existência de 3 pacientes distintos no conjunto de dados, suportado pelo equilíbrio do agrupamento hierárquico em K=3 (24, 20 e 27 sequências). A hipótese de 2 pacientes surge como alternativa plausível devido à maior separação pelo silhouette score.

A Declaração de Honra

Cada group deve preencher e assinar a seguinte declaração.

Declaração de Honra

Nós, membros do grupo 109 identificados abaixo

David Alves, No 107603
Luana Oliveira, No 109251

declaramos por nossa honra que este trabalho, realizado ao abrigo da cadeira de Introdução à Aprendizagem Automática é resultado do trabalho dos seguintes membros do grupop: members.

As contribuições individuais são:

David Alves - Preparar questões R5a R5b R6a R6b R6c R7c R8a Q10 - Código, simulação e justificação das respostas

Luana Oliveira - Preparar questões R2a R2b R2c R3a R4a R7a R7b Q9 - Código, simulação e justificação das respostas

Declaramos que este trabalho é original e que foi feito segundo os regulamentos académicos.

Nome, Número e	Assinatura
David Alves, No 107603	David Alves
Luana Oliveira, No 109251	Luana Oliveira

Data: 17/10/2026

B Declaração do Uso de Inteligência Artifiial

Cada aluno deve preencher e assinar uma cópia individual desta declaração.

Declaração do Uso de Inteligência Artificial

Nome do Aluno: Luana Oliveira

Número do Aluno: 109251

Declaro que todas as decisões e conteúdo técnico deste laboratório são da minha autoria.

Utilizei a Inteligência Artificial como apoio para compreender o código e confirmar se a maneira que eu o escrevi estava correta. Também usei para consolidar conceitos de Python fundamentais para a cadeira.

Declaro que compreendo completamente o funcionamento de todas as componentes do projeto, mesmo as que foram desenvolvidas com o apoio das ferramentas de IA listadas acima."

Data: 17/10/2026 Assinatura: Luana Oliveira

B Declaração do Uso de Inteligência Artifiial

Cada aluno deve preencher e assinar uma cópia individual desta declaração.

Declaração do Uso de Inteligência Artificial

Nome do Aluno: David Alves

Número do Aluno: 107603

Declaro que todas as decisões e conteúdo técnico deste laboratório são da minha autoria.

- Utilizei inteligência artificial para gerar e entender o codigo para a realização deste projeto e como suporte à aprendizagem ativa.

Declaro que compreendo completamente o funcionamento de todas as componentes do projeto, mesmo as que foram desenvolvidas com o apoio das ferramentas de IA listadas acima."

Data: 17/10/2026 Assinatura: David Alves